

Análisis de las Propiedades Químicas de Vinos Italianos mediante Componentes Principales

Miguel Adrián Gheorghe

Ejercicio 4

Carga y Preparación. Carga el dataset wine, elimina la primera columna (que contiene la clase) y realiza una breve exploración estadística. ¿Crees que las variables están en la misma escala? Justifica si es necesario estandarizar.

```
library(HDclassif)
library(tidyverse)
library(factoextra)
library(patchwork)
library(corrplot)

data(wine)
wine_data <- wine[, -1]

str(wine_data)
```

```
'data.frame':  178 obs. of  13 variables:
 $ V1 : num  14.2 13.2 13.2 14.4 13.2 ...
 $ V2 : num  1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35 ...
 $ V3 : num  2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17 2.27 ...
 $ V4 : num  15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
 $ V5 : int  127 100 101 113 118 112 96 121 97 98 ...
 $ V6 : num  2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
 $ V7 : num  3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15 ...
 $ V8 : num  0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29 0.22 ...
 $ V9 : num  2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85 ...
 $ V10: num  5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2 7.22 ...
 $ V11: num  1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01 ...
```

```
$ V12: num  3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85 3.55 ...
$ V13: int  1065 1050 1185 1480 735 1450 1290 1295 1045 1045 ...
```

```
head(wine_data)
```


```
      V1  V2  V3  V4  V5  V6  V7  V8  V9  V10  V11  V12  V13
1 14.23 1.71 2.43 15.6 127 2.80 3.06 0.28 2.29 5.64 1.04 3.92 1065
2 13.20 1.78 2.14 11.2 100 2.65 2.76 0.26 1.28 4.38 1.05 3.40 1050
3 13.16 2.36 2.67 18.6 101 2.80 3.24 0.30 2.81 5.68 1.03 3.17 1185
4 14.37 1.95 2.50 16.8 113 3.85 3.49 0.24 2.18 7.80 0.86 3.45 1480
5 13.24 2.59 2.87 21.0 118 2.80 2.69 0.39 1.82 4.32 1.04 2.93  735
6 14.20 1.76 2.45 15.2 112 3.27 3.39 0.34 1.97 6.75 1.05 2.85 1450
```

```
summary(wine_data)
```


V1	V2	V3	V4
Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60
1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20
Median :13.05	Median :1.865	Median :2.360	Median :19.50
Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49
3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50
Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00
V5	V6	V7	V8
Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300
1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700
Median : 98.00	Median :2.355	Median :2.135	Median :0.3400
Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619
3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375
Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600
V9	V10	V11	V12
Min. :0.410	Min. : 1.280	Min. :0.4800	Min. :1.270
1st Qu.:1.250	1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938
Median :1.555	Median : 4.690	Median :0.9650	Median :2.780
Mean :1.591	Mean : 5.058	Mean :0.9574	Mean :2.612
3rd Qu.:1.950	3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170
Max. :3.580	Max. :13.000	Max. :1.7100	Max. :4.000
V13			
Min. : 278.0			
1st Qu.: 500.5			
Median : 673.5			
Mean : 746.9			

3rd Qu.: 985.0
Max. :1680.0

```
cor(wine_data) |>
  corrrplot(method = "number", type = "upper", number.digits = 1, number.cex = 0.8,
    col = colorRampPalette(c("green", "gray", "blue"))(200))
```




```
boxplot(wine_data)
```



Hemos imprimido dos gráficos: la primera muestra la correlación que hay entre variables y la segunda un boxplot para poder ver la varianza de los datos y sus magnitudes. Analizando este último, vemos que la variable V13 tiene una varianza muchísimo mayor que las demás. Lo óptimo ahora mismo sería normalizar o escalar los datos:

```
wine_data <- scale(wine_data)
boxplot(wine_data, )
```



Una vez escalado, podemos ver que hay algunos outliers en algunas variables, que se representan como puntos fuera de los límites.

Ejercicio 5

Ejecución del PCA. Realiza el PCA sobre `wine_data` asegurando que los datos se escalen (`scale = TRUE`).

1. ¿Cuánta varianza explican las dos primeras componentes? 1. ¿Cuántas componentes necesitarías para retener al menos el 80% de la información original? Dibuja el Scree Plot.

```
pca_result_wine <- prcomp(wine_data, center = TRUE, scale = TRUE)
summary(pca_result_wine)
```


Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.169	1.5802	1.2025	0.95863	0.92370	0.80103	0.74231
Proportion of Variance	0.362	0.1921	0.1112	0.07069	0.06563	0.04936	0.04239
Cumulative Proportion	0.362	0.5541	0.6653	0.73599	0.80162	0.85098	0.89337

	PC8	PC9	PC10	PC11	PC12	PC13
Standard deviation	0.69292	0.59628	0.54583	0.48397	0.44334	0.41802
Proportion of Variance	0.03581	0.03031	0.02763	0.02463	0.02256	0.02144
Cumulative Proportion	0.92918	0.95949	0.98712	1.00000	1.00000	1.00000

Standard deviation	0.59034	0.53748	0.5009	0.47517	0.41082	0.32152
Proportion of Variance	0.02681	0.02222	0.0193	0.01737	0.01298	0.00795
Cumulative Proportion	0.92018	0.94240	0.9617	0.97907	0.99205	1.00000

```
fviz_eig(pca_result_wine, addlabels = TRUE,
        ylim = c(0, 50), title = "Scree Plot", ncp = 13)
```



La varianza explicada representa cuanta información retiene cada componente principal. Se obtiene a partir de `pca_result_wine$sdev^2 / sum(pca_result_wine$sdev^2)`. Las componentes principales son los nuevos ejes en el espacio, los vectores que definen la rotación de los datos originales. Se obtiene de la matriz de rotación `pca_result_wine$rotation`, cada columna es un autovector. Loadings son las correlaciones entre las variables originales y las componentes principales. Interpreta cuanto mide cada componente. Se obtiene de `pca_result_wine$rotation` o visualmente con la función `fviz_pca_var()`. Scores son las coordenadas de cada individuo en el nuevo sistemas de eje marcado por las componentes principales. Se obtienen las coordenadas de los elementos en `pca_result_wine$x`.

Analizando el Scree Plot, las dos primeras varianzas explican un 36.2% y un 19.2%. Este conjunto nos permite retener un $36.2 + 19.2 = 55.4\%$ de la información. Para retener el 80% de la información necesitaríamos las primeras 5 componentes, reteniendo 80.2%.

Ejercicio 6


Interpretación de Pesos (Loadings). Examina la matriz de rotación (rotation).

1. Identifica las 3 variables que más contribuyen (positiva o negativamente) a la PC1. 1. Basándote en esto, ¿qué crees que intenta “medir” la primera componente en el perfil químico de un vino?

```
sort(abs(pca_result_wine$rotation[, 1]), decreasing = TRUE)[1:3]
```

```
      V7      V6      V12  
0.4229343 0.3946608 0.3761674
```

```
fviz_pca_var(pca_result_wine, col.var = "contrib",  
             gradient.cols = c("gray", "green", "blue"),  
             repel = TRUE, title = "Variables y sus contribuciones")
```



Para ver las variables que más contribuyen a la PC1, analizamos la primera columna (primera PC) de la matriz de loadings. Para obtener los mayores, ordenamos el mayor absoluto de cada peso y obtenemos las 3 primeras. En este caso las que más contribuyen son V7, V6 y V12. También lo podemos obtener a partir del gráfico. Las que más contribuyen son las flechas más largas y pegadas al eje X. Como apuntan a la parte negativa del eje X, estas variables están negativamente correlacionadas con la PC1.

Ejercicio 7

Visualización: El Biplot. Genera un biplot del análisis.


1. Observa las flechas de Total phenols (V6)* y Flavanoids (V7)*. ¿Qué puedes decir sobre su correlación? 1. Identifica si hay algún grupo de vinos que se separe claramente del resto. Colorea los puntos por la variable class original para verificarlo.

* Como en el dataset no sale el nombre de la columna, he buscado en internet a que columna pertenece cada nombre

```
fviz_pca_biplot(pca_result_wine, repel = TRUE, habillage = wine[, 1],
  col.var = "#2E9FDF", col.ind = "#696969", label = "none",
  title = "Biplot de wine", legend.title = "Cultivar",
  addEllipses = TRUE)
```

Ignoring unknown labels:

* linetype : "Cultivar"



Como vimos anteriormente, estaban en la parte negativa del eje X y bastante juntas, es decir, en la naturaleza de estos vinos, si uno tiene muchos flavonoids (V7), es casi seguro que también tendrá muchos Total phenols (V6). Además, ambas tienen una correlación inversa con la PC1.

Preguntas de “Estructuras Algebraicas”

Ejercicio 1

Considerando el dataset `wine_data` con 13 variables numéricas, ¿cómo describirías el espacio vectorial en el que reside cada observación (cada vino) antes de aplicar el ACP? ¿Cuál es la dimensión de este espacio?

Cada variable (columna) representa una dimensión en el sistema de coordenadas. Como tenemos 13 variables, estaríamos trabajando en un espacio vectorial $\mathbb{R}^{13}$.

Ejercicio 2

El ACP genera nuevos componentes principales. Estos componentes forman una nueva base para el espacio de los datos. ¿Por qué esta nueva base es ortogonal? ¿Cómo se relaciona la construcción de esta base ortogonal con el proceso de diagonalización de la matriz de covarianza (o correlación)?

Es ortogonal porque el PCA busca direcciones de varianza máxima que no estén correlacionadas entre sí. La matriz de covarianza Σ se puede diagonalizar como PDP^T donde P es la matriz de paso formado por los autovectores y D una matriz diagonal de autovalores.

Ejercicio 3

Los componentes principales son, de hecho, los autovectores de la matriz de (co)varianza de los datos escalados. En términos de una transformación lineal asociada a esta matriz, ¿qué propiedad fundamental satisface un autovector? ¿Cómo se manifiesta esta propiedad en el contexto del ACP y la preservación de la varianza?

El autovector es la flecha que apunta al lugar donde hay más información, y su propiedad de no rotar asegura que esa información se capture de forma pura, sin mezclarse con otras dimensiones.

Ejercicio 4

Los autovalores asociados a cada componente principal cuantifican la cantidad de varianza de los datos que se encuentra en la dirección de ese componente. ¿Por qué el primer componente principal se corresponde siempre con el autovector asociado al mayor autovalor?

El objetivo de PCA es maximizar la varianza capturada en el primer paso (ese máximo es el autovalor dominante). Esto asegura que la PC1 sea el eje que mejor resume la dispersión de los datos.

Ejercicio 5

Al decidir retener solo los primeros k componentes principales (por ejemplo, los 2 o 3 que explican la mayor parte de la varianza), estamos esencialmente proyectando los datos originales sobre un subespacio vectorial de menor dimensión k . ¿Por qué se elige precisamente el subespacio generado por los k primeros componentes principales para lograr la mejor representación posible de los datos originales en una dimensión menor, en términos de la varianza preservada?

Al retener los mayores autovalores, garantizamos que estamos preservando la máxima varianza total posible de los datos originales en un espacio de menor dimensión

Ejercicio 6

Observando los loadings (`pca_result_wine$rotation`), ¿qué variables químicas originales parecen tener la mayor influencia en los primeros componentes principales? ¿Cómo interpretarías lo que representan estos primeros componentes en el contexto de las propiedades de los vinos? (Por ejemplo, el primer componente podría representar alguna medida general de la “calidad” o “densidad” del vino).

Variables como V6, V7 y V12 (conseguidos y analizados anteriormente) son los que dominan la PC1. Por ejemplo, en la naturaleza de estos vinos, si uno tiene muchos flavonoids (V7), es casi seguro que también tendrá muchos Total phenols (V6).

Ejercicio 7

Basado en el biplot (y opcionalmente, el análisis de clustering), ¿logran los primeros dos componentes principales capturar las diferencias entre los vinos de los distintos cultivares de forma que se vean visualmente separados? ¿Qué te indica esto sobre la utilidad del ACP para este dataset particular?

Sí, las dos primeras componentes logran separar los tres cultivares en nubes de puntos claramente diferenciadas (analizar el biplot anterior). La utilidad aquí con PCA es que hemos simplificado el problema de 13 a 2 variables sin perder la capacidad de clasificar los vinos.