

Práctica PCA

Miguel Adrián Gheorghe


Ejercicio 4

Carga y Preparación. Carga el dataset wine, elimina la primera columna (que contiene la clase) y realiza una breve exploración estadística. ¿Crees que las variables están en la misma escala? Justifica si es necesario estandarizar.


```
library(HDclassif)
library(tidyverse)
library(factoextra)
library(patchwork)
library(corrplot)

data(wine)
wine_data <- wine[, -1]

cor(wine_data) |>
  corrplot(method = "number", type = "upper",
           col = colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD",
                                   "#4477AA"))(200))
```




```
boxplot(wine_data)
```



Hemos imprimido dos gráficos: la primera muestra la correlación que hay entre variables y la segunda un boxplot para poder ver la varianza de los datos y sus magnitudes. Analizando este

último, vemos que la variable V13 tiene una varianza muchísimo mayor que a los demás. Lo óptimo ahora mismo sería normalizar o escalar los datos:

```
wine_data <- scale(wine_data)
boxplot(wine_data)
```




Una vez escalado, podemos ver que hay algunos outliers en algunas variables, que se representan como puntos fuera de los bigotes.

Ejercicio 5

Ejecución del PCA. Realiza el PCA sobre wine_data asegurando que los datos se escalen (scale = TRUE).

1. ¿Cuánta varianza explican las dos primeras componentes?
2. ¿Cuántas componentes necesitarías para retener al menos el 80% de la información original? Dibuja el Scree Plot.

```
pca <- prcomp(wine_data, center = TRUE, scale = TRUE)
fviz_eig(pca, addlabels = TRUE, ylim = c(0, 50), title = "Scree Plot", ncp = 13)
```



Analizando el Scree Plot, las dos primeras varianzas explican un 36.2% y un 19.2%. Este conjunto nos permite retener un $36.2 + 19.2 = 55.4\%$ de la información. Para retener el 80% de la información necesitaríamos las primeras 5 componentes, reteniendo 80.2%.

Ejercicio 6

Interpretación de Pesos (Loadings). Examina la matriz de rotación (rotation).

1. Identifica las 3 variables que más contribuyen (positiva o negativamente) a la PC1.
2. Basándote en esto, ¿qué crees que intenta “medir” la primera componente en el perfil químico de un vino?

```
sort(abs(pca$rotation[, 1]), decreasing = TRUE)[1:3]
```

```


      V7      V6      V12
0.4229343 0.3946608 0.3761674

```

```

fviz_pca_var(pca, col.var = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
             repel = TRUE, title = "Variables y sus contribuciones")

```



Para ver las variables que más contribuyen a la PC1, analizamos la primera columna (primera PC) de la matriz de loadings. Para obtener los mayores, ordenamos el mayor absoluto de cada peso y obtenemos las 3 primeras. En este caso las que mas contribuyen son V7, V6 y V12. Tambien lo podemos obtener a partir del gráfico. Las que más contribuyen son las flechas más largas y pegadas al eje X. Como apuntan a la parte negativa del eje X, estas variables están negativamente correlacionadas con la PC1.


Ejercicio 7

Visualización: El Biplot. Genera un biplot del análisis.

1. Observa las flechas de Total phenols (V6)* y Flavanoids (V7)*. ¿Qué puedes decir sobre su correlación?
2. Identifica si hay algún grupo de vinos que se separe claramente del resto. Colorea los puntos por la variable class original para verificarlo.

* Como en el dataset no sale el nombre de la columna, he buscado en internet a que columna pertenece cada nombre

```
fviz_pca_biplot(pca, repel = TRUE,
                col.var = "#2E9FDF", col.ind = "#696969",
                title = "Biplot de wine")
```



Como vimos anteriormente, estaban en la parte negativa del eje X y bastante juntas, es decir, en la naturaleza de estos vinos, si uno tiene muchos flavonoids (V7), es casi seguro que también tendrá muchos Total phenols (V6). Además, ambas tienen una correlación inversa con la PC1.