



Proyecto: Arquitectura de Influencia en Ecosistemas de Consumo

Dataset Amazon

Universidad de Málaga

Curso 2025–2026

1 Introducción

En este proyecto de **Aprendizaje Basado en Proyectos (ABP)** se pretende que **actuéis** como analistas de datos para entender cómo se estructuran las relaciones entre productos y usuarios en Amazon. El objetivo es que **apliquéis** las técnicas vistas en clase, en particular, de reducción de datos, grafos y clasificación para predecir el comportamiento del mercado.

Información Base

- **Dataset sugerido:** Amazon Product Reviews (CSV)
- **Herramientas:** R, Quarto y las librerías vistas en clase en cada tema.

2 Contenido del Proyecto

2.1 Bloque I: Análisis de Componentes Principales (PCA)

En esta primera fase, el objetivo es extraer las dimensiones latentes que definen el éxito de un producto.

- **Tarea:** Reducción de dimensionalidad. Construir una tabla de métricas por producto (Rating promedio, número de reseñas, precio, longitud promedio del texto de la reseña).
- **Análisis:** Aplicar PCA para reducir estas variables a 2 o 3 componentes principales.
- **Interpretación:** ¿Qué representan los ejes? (Ej: ¿El PC1 separa productos "Premium" de "Ventas Masivas"?). **Debéis** justificar la retención de varianza con un *Scree Plot*. Si solo hay código no se evalúa, **debéis** ir extrayendo conocimiento en cada paso, **interpretad**, **analizad** resultados. **Justificad** la retención de varianza mediante el criterio de Kaiser o el gráfico de sedimentación, e **interpretad** qué significan físicamente los nuevos ejes.

2.2 Bloque II: Análisis de Redes Sociales (SNA)

Una vez reducida la dimensionalidad, pasaréis a modelar el ecosistema de consumo como una red compleja bidimensional.

- **Tarea:** Construir la red de usuarios en un **grafo de coparticipación**. Dos productos están conectados si han sido reseñados por los mismos N usuarios. Debéis justificar la elección de N basándoos en la densidad del grafo resultante.
- **Análisis:** Utilizad métricas de centralidad: **PageRank** (para identificar productos "faro"), **Betweenness** (para identificar productos puente entre categorías), etc.
- **Detección de Comunidades:** Mediante el algoritmo de **Louvain** o **Walktrap**, analizad si las comunidades coinciden con aspectos geográficos o de categorías de consumo u otras características.
- **Visualización:** Mostrad las comunidades de productos más densas. Manejad eficientemente objetos de grafos de gran tamaño (limpieza de nodos aislados, simplificación de aristas).

2.3 Bloque III: Clasificación Basada en Enlaces (Link-based)

Finalmente, explotaréis la topología de la red construida para inferir información oculta del mercado.

- **Tarea:** Utilizad la posición de un producto en el grafo para clasificarlo por diferentes métricas.
- **Reto:** Si un producto no tiene categoría asignada, ¿podéis predecirla basándoos en la categoría de sus "vecinos" en la red de usuarios? (Homofilia). Utilizad la estructura del grafo para predecir si un usuario pertenece a una categoría "Elite" o para recomendar un enlace (*Link Prediction*), por ejemplo, identificando qué productos suelen adquirirse de forma conjunta (co-compra) basándose en la estructura de la red.

3 Anexo: Diario de Interacción con IA (Prompt Log)

Debéis entregar un documento (o sección final) que detalle vuestra "conversación" con la IA:

- **Registro de Prompts:** ¿Qué le preguntasteis exactamente?
- **Refinamiento:** "La IA me dio este código, pero daba error de memoria. Le pedí que lo optimizara usando `data.table` en lugar de `data.frame`". Me dio error y yo volví a pedirle...Ver la iteración con la IA.
- **Validación Humana:** "La IA sugirió usar el algoritmo X, pero tras leer la documentación de `igraph`, decidí usar el Y porque mi grafo es dirigido/no dirigido".
- **Detección de Alucinaciones:** Identificad al menos un momento donde la IA sugirió una función inexistente o un razonamiento estadístico erróneo y cómo lo corregisteis.

Para una consulta a la IA, no quiero ver solo el prompt, sino:

1. Prompt inicial.
2. Código erróneo o ineficiente generado por la IA.
3. Crítica vuestra: "La IA sugirió `layout_with_fr` para visualizar el grafo, pero con 50,000 nodos el tiempo de cómputo era infinito".
4. Solución final: "Investigamos y cambiamos a un layout lineal o filtramos el grafo por el k-core principal".

4 Requisitos en todo el proyecto

1. **Justificación de argumentos, parámetros o Hiperparámetros sugeridos por la IA:** Si la IA sugiere un *threshold* para el PCA o un método específico de detección de comunidades, **debéis** realizar un **análisis de sensibilidad**: ¿Cómo cambia el resultado si **cambiáis** el parámetro?
2. **Validación Cruzada de Métodos: Comparad** los resultados del PCA con los de SNA. ¿Los usuarios con mayor centralidad en el grafo son también los que aparecen como *outliers* en el biplot del PCA o todo lo contrario? **Cruza** los resultados de los distintos métodos.
3. **Investigación Reproducible:** Obligatorio el uso de **Quarto**. El código debe correr de principio a fin, con control de semillas (`set.seed`) y gestión de dependencias. Si el proyecto quarto no compila, no se evalúa el proyecto. **Debéis** entregar el directorio comprimido con los ficheros fuentes y la salida que devuelve.

5 Consejos Técnicos

Dada la magnitud de los datos de Amazon, se recomienda seguir estas pautas para garantizar la fluidez del análisis en R:

- **Gestión de Datos:** Utilizad la librería `data.table` para la lectura (`fread`) y el procesamiento inicial. Es significativamente más rápida y eficiente en memoria que los *data.frames* estándar.
- **Estrategia de Filtrado:** No es necesario (ni recomendable) procesar todo el dataset de golpe. **Filtrad** por una **subcategoría específica** (ej. Videojuegos, Libros de Ciencia Ficción) o por un rango temporal que limite el número de productos a analizar.
- **Construcción del Grafo:** Si el número de productos es elevado, la construcción del grafo de co-participación puede ser lenta. **Considerad** usar un umbral N (mínimo de usuarios compartidos) lo suficientemente alto para reducir la densidad de la red.
- **Visualización Progresiva:** Para grafos de más de 5,000 nodos, **evitad** los *layouts* por defecto en tiempo real.

6 Defensa Crítica

En caso de que se detecte copia de material en los proyectos o uso excesivo de la IA se citará a los alumnos para entrevista oral. **Debéis** explicar el "porqué" de cada algoritmo sin leer el código, las técnicas usadas. Si **usáis IA debéis enteraros** claramente qué hace el código sugerido. Los dos puntos del proyecto dependen totalmente de esta entrevista.

7 Rúbrica de evaluación (2 Puntos)

Criterio	Peso	Requisito Clave
Calidad	0.8 pts (40 %)	Calidad del material proporcionado en cuanto a uso de los contenidos de la asignatura.
Presentación	0.4 pts (20 %)	Calidad de la presentación realizada con Quarto.
Reproducibilidad	0.4 pts (20 %)	Script en RMarkdown/Quarto que funcione de principio a fin con el dataset original.
Anexo de Uso de IA	0.4 pts (20 %)	Bitácora de prompts. Debéis incluir la interacción con la IA, ejemplos reales y cómo iterasteis con el prompt para solucionar el problema o realizar lo que queríais ; ejemplos reales de un error que cometió la IA y cómo lo solucionasteis .